

```

#
=====
=====
# SCRIPT DE REPLICABILIDADE CIENTÍFICA
# Título: Análise Lexical Quantitativa e Posicionamento Metodológico dos
# Instrumentos de Governança Climática do Urban-LEDS II no Brasil
# Autor: Arthur Reis
# Repositório: https://github.com/arthurreis-cr/Artigo
#
=====
=====

# 0. CARREGAMENTO DE PACOTES
library(quanteda)
library(stringi)
library(ggplot2)
library(tidyr)
library(dplyr)

# 1. NORMALIZAÇÃO DO CORPUS EM ASCII
# Lê os relatórios armazenados em PDF na pasta 'dados_pdf'
dados_brutos <- readtext::readtext("./dados_pdf/*.pdf")
corpus_relatorios_A1 <- corpus(dados_brutos)

textos_ascii <- stri_trans_general(as.character(corpus_relatorios_A1), "Latin-ASCII")
corpus_normalizado <- corpus(textos_ascii)
docnames(corpus_normalizado) <- docnames(corpus_relatorios_A1)

# 2. DEFINIÇÃO DO DICIONÁRIO TEMÁTICO (ESTRUTURA ORIGINAL)
dict_raw <- list(
  Tecnico_Analitico = c(
    "modelagem*_climatica*", "modelagem*_hidrologica*", "modelagem*_hidrodinamica*",
    "modelo*_hidrologico*", "modelo*_hidrodinamico*", "modelo*_microclimatico*",
    "simulacao*_microclimatica*", "simulacao*_de_inundacao*", "simulacao*_de_inundacoes",
    "simulacao*_computacional*", "simulacoes_computacionais",
    "envi_met", "envimet", "caddies", "swmm", "infoworks", "software*",
    "programa*_de_simulacao*",
    "plataforma*_computacional*", "grade*_de_celulas", "curva*_de_danos",
    "periodo*_de_retorno",
    "vulnerabilidade*_tecnica*", "vulnerabilidade*_fisica*", "dado*_de_precipitacao*",
    "dados_de_precipitacao"
  ),

  Planejamento_Urbano_e_Design = c(

```

```
"sbn", "solucao*_baseada*_na_natureza", "solucoes_baseadas_na_natureza",
"infraestrutura*_verde*", "infraestrutura*_azul*", "infraestrutura*_turquesa*",
"telhado*_verde*", "parede*_verde*", "jardim*_de_chuva*", "jardins_de_chuva",
"pavimento*_permeavel*", "pavimentos_permeaveis", "bacia*_de_retencao*",
"bacias_de_retencao",
"sistema*_de_drenagem*_sustentavel*", "reuso_adaptativo", "reuso*_adaptativo*"
),
```

```
Governanca_e_Arranjos_Institucionais = c(
"plano*_de_acao_climatica*", "plano*_local*_de_acao*_climatica*", "plac",
"existencia_de_planos", "politica*_de_adaptacao*",
"capacidade*_institucional*", "capacidade*_administrativa*", "economia*_circular*",
"metabolismo*_urbano*", "arranjo*_institucional*", "parceria*_publico_privada*",
"parcerias_publico_privadas",
"coordenacao*_multinivel", "articulacao*_multiescalar", "integracao*_vertical",
"integracao*_horizontal", "continuidade*_institucional*", "marco*_regulatorio*",
"marcos_regulatorios",
"ciclo*_de_politicas", "longo_prazo", "institucionalizacao*", "alocacao*_de_recurso*"
),
```

```
Justica_Socioinstitucional = c(
"justica*_climatica*", "justica*_ambiental*", "equidade*_social*",
"vulnerabilidade*_social*", "vulnerabilidade*_socioeconomica*",
"assentamento*_informal*", "assentamentos_informais", "favela*",
"morador*_de_baixa_renda", "moradores_de_baixa_renda", "participacao*_popular*",
"co_producao*_do_conhecimento", "coproducao*", "co_producao*",
"mapeamento*_participativo*", "desigualdade*_estrutural*", "exclusao*_social*"
),
```

```
Organizacao_Ecologica_do_Territorio = c(
"sistema*_de_informacao*_geografica*", "sig", "gis", "sensoriamento*_remoto*",
"corredor*_ecologico*", "conectividade*_ecologica*", "seguranca*_ecologica*",
"resistencia*_minima*_acumulada*", "mcr", "sensibilidade*_ecologica*",
"fonte*_ecologica*", "fontes_ecologicas", "servico*_ecossistemico*",
"servicos_ecossistemicos",
"mancha*_de_paisagem*", "manchas_de_paisagem"
)
)
```

Transliteração ASCII e criação do objeto dictionary

```
dict_ascii_list <- lapply(dict_raw, function(x) stri_trans_general(x, "Latin-ASCII"))
```

```
dict_final <- dictionary(dict_ascii_list)
```

3. TOKENIZAÇÃO E TRATAMENTO TEXTUAL

```
tokens_limpos <- tokens(corpus_normalizado, remove_punct = TRUE) %>%
  tokens_tolower() %>%
  tokens_compound(pattern = dict_final)
```

4. APLICAÇÃO DO DICIONÁRIO E MATRIZ DFM

```
dfm_lookup_resultado <- dfm(tokens_limpos) %>%
  dfm_lookup(dictionary = dict_final)
```

```
tabela_frequencias <- convert(dfm_lookup_resultado, to = "data.frame")
```

5. NORMALIZAÇÃO PELO TOTAL DE PALAVRAS

```
tabela_frequencias$Total_Palavras <- as.vector(ntoken(tokens_limpos))
```

```
tabela_frequencias$Pct_Tecnico_Analitico <- (tabela_frequencias$Tecnico_Analitico /
tabela_frequencias$Total_Palavras) * 100
tabela_frequencias$Pct_Planejament_Urbano_e_Design <-
(tabela_frequencias$Planejament_Urbano_e_Design / tabela_frequencias$Total_Palavras) *
100
tabela_frequencias$Pct_Governanca_e_Arranjos_Inst <-
(tabela_frequencias$Governanca_e_Arranjos_Institucionais /
tabela_frequencias$Total_Palavras) * 100
tabela_frequencias$Pct_Justica_Socioinstitucional <-
(tabela_frequencias$Justica_Socioinstitucional / tabela_frequencias$Total_Palavras) * 100
tabela_frequencias$Pct_Organizacao_Ecologica <-
(tabela_frequencias$Organizacao_Ecologica_do_Territorio /
tabela_frequencias$Total_Palavras) * 100
```

6. MAPEAMENTO DAS CATEGORIAS (SEM CATEGORIA OUTROS)

```
df_reais <- tabela_frequencias %>%
  mutate(
    Categoria = case_when(
      grepl("Fortaleza|Recife.*Plano|PLAC", doc_id, ignore.case = TRUE) ~ "I. Planejamento
Estratégico (PLAC)",
      grepl("Betim|Sorocaba|ARC|Risco", doc_id, ignore.case = TRUE) ~ "II. Diagnóstico de
Risco (ARC)",
      grepl("Belo Horizonte|Recife.*insumos|RIT", doc_id, ignore.case = TRUE) ~ "III. Insumos
Técnicos (RIT)"
    ),
    doc_id_label = case_when(
      grepl("Betim", doc_id, ignore.case = TRUE) ~ "Betim\n(ARC)",
      grepl("Belo Horizonte", doc_id, ignore.case = TRUE) ~ "Belo Horizonte\n(RIT)",
      grepl("Fortaleza", doc_id, ignore.case = TRUE) ~ "Fortaleza\n(PLAC)",
      grepl("Recife.*(Plano|PLAC)", doc_id, ignore.case = TRUE) ~ "Recife\n(PLAC)",
      grepl("Recife.*(insumos|RIT)", doc_id, ignore.case = TRUE) ~ "Recife\n(RIT)",
```

```

    grepl("Sorocaba", doc_id, ignore.case = TRUE) ~ "Sorocaba\n(ARC)",
    TRUE ~ doc_id
  )
)

```

7. FORMATO LONGO PARA PLOTAGEM

```

df_longo <- df_reais %>%
  select(
    doc_id_label, Categoria,
    Pct_Tecnico_Analitico, Pct_Planejament_Urbano_e_Design,
    Pct_Governanca_e_Arranjos_Inst, Pct_Justica_Socioinstitucional,
    Pct_Organizacao_Ecologica
  ) %>%
  pivot_longer(
    cols = starts_with("Pct_"),
    names_to = "Dimensao",
    values_to = "Porcentagem"
  ) %>%
  mutate(
    Dimensao = recode(
      Dimensao,
      Pct_Tecnico_Analitico = "Técnico-Analítico (D1)",
      Pct_Planejament_Urbano_e_Design = "Planejamento e Design (D2)",
      Pct_Governanca_e_Arranjos_Inst = "Governança e Arranjos (D3)",
      Pct_Justica_Socioinstitucional = "Justiça Socioinstitucional (D4)",
      Pct_Organizacao_Ecologica = "Organização Ecológica (D5)"
    )
  )
)

```

8. RENDERIZAÇÃO DO GRÁFICO FINAL

```

grafico_final <- ggplot(df_longo, aes(x = doc_id_label, y = Porcentagem, fill = Dimensao)) +
  geom_bar(stat = "identity", position = position_dodge(preserve = "single"), width = 0.7) +
  facet_grid(. ~ Categoria, scales = "free_x", space = "free") +
  theme_minimal() +
  scale_fill_brewer(palette = "Set1") +
  labs(
    title = "Distribuição das Dimensões da Sustentabilidade no Urban-LEDS II",
    subtitle = "Análise Quantitativa de Conteúdo Comparando 3 Categorias de Instrumentos
Climáticos",
    x = "Município Analisado (e Tipo de Documento)",
    y = "Frequência Relativa (% do total de palavras do relatório)",
    fill = "Dimensão Operacional (Dicionário)"
  ) +
  theme(

```

```

axis.text.x = element_text(face = "bold", size = 9, color = "black"),
axis.title = element_text(face = "bold", size = 10),
strip.background = element_rect(fill = "grey90", color = NA),
strip.text = element_text(face = "bold", size = 9, color = "black"),
legend.position = "bottom",
legend.box = "horizontal",
legend.title = element_text(face = "bold", size = 9),
legend.text = element_text(size = 8),
plot.title = element_text(face = "bold", size = 12, hjust = 0.5),
plot.subtitle = element_text(size = 9, hjust = 0.5, face = "italic"),
panel.spacing = unit(1, "lines")
) +
guides(fill = guide_legend(nrow = 2, byrow = TRUE))

print(grafico_final)

# Exportação do Gráfico em alta resolução
ggsave("figuras/01_distribuicao_dimensoes.png", plot = grafico_final, width = 11, height = 6.5,
dpi = 300)

#
=====
=====
# 9. BLOCO DE VALIDAÇÃO METODOLÓGICA DA ANÁLISE DE CONTEÚDO
#
=====
=====

message("\n=== 1. DIAGNÓSTICO DE PRODUTIVIDADE DO DICIONÁRIO ===")

# Matriz completa sem sumarizar por categoria para ver termo por termo
dfm_termos_individuais <- dfm_select(dfm(tokens_limpos), pattern = dict_final)
freq_por_termo <- colSums(dfm_termos_individuais)

# Exibe os 10 termos mais frequentes capturados no estudo todo
cat("\n--> Top 10 termos mais frequentes capturados:\n")
print(head(sort(freq_por_termo, decreasing = TRUE), 10))

# Exibe termos do dicionário que NUNCA foram encontrados nos documentos
termos_zerados <- freq_por_termo[freq_por_termo == 0]
cat("\n--> Total de termos sem ocorrência no corpus:", length(termos_zerados), "de",
length(freq_por_termo), "\n")

```

```
message("\n=== 2. VALIDAÇÃO DE CONTEXTO (AMOSTRAGEM KWIC) ===")
# Extrai 15 amostras aleatórias do texto com 5 palavras antes e 5 depois do match
set.seed(123) # Para reprodutibilidade
amostra_validacao <- kwic(tokens_limpos, pattern = dict_final, window = 5) %>%
  as.data.frame() %>%
  slice_sample(n = min(15, nrow(.))) %>%
  select(docname, pre, keyword, post, pattern)

cat("\n---> Amostra aleatória de ocorrências para verificação de falsos positivos:\n")
print(amostra_validacao)
```

```
message("\n=== 3. AUDITORIA DA DIMENSÃO D4 (JUSTIÇA SOCIOINSTITUCIONAL) ===")
# Valida se termos isolados como "favela", "equidade" ou "social" aparecem no corpus
# para testar se o problema foi a rigidez dos termos compostos
tokens_simples_d4 <- c("justica*", "equidade*", "social*", "favela*", "vulnerabilidade*",
  "participacao*")
dfm_d4_checagem <- dfm_select(dfm(tokens_limpos), pattern = tokens_simples_d4)

cat("\n---> Frequência de palavras-chave simples relacionadas à dimensão D4:\n")
print(colSums(dfm_d4_checagem))
```